

실험 보고서 — Multi-Interest Recommendation via Text Embedding

Course: AI506 Data Mining and Search — Term Project

Model: Model-1 (Simple Text Embedding Baseline)

작성일: 2026-05-09

1. 모델 개요

1-1. 핵심 아이디어

학습 가능한 파라미터 없이, pre-trained text embedding만으로 동작하는 추천 시스템.

유저마다 **k개의 interest vector**를 유지하며, 검색·클릭 이벤트가 발생할 때마다 스트리밍 방식으로 업데이트한다.

1-2. 알고리즘

Interest 초기화

유저를 처음 만났을 때 interest vectors를 **랜덤 정규분포** → **L2 정규화**로 초기화한다.

- 0벡터 초기화는 k개 벡터 간 거리가 모두 동일해 soft assignment가 uniform이 되므로 제외.
- 랜덤 초기화는 k개 벡터가 초기부터 서로 다른 방향을 가리켜 specialization을 유도한다.

Soft Assignment 업데이트

새 embedding **e**가 들어올 때마다 각 interest vector **v_i**와의 코사인 거리를 기반으로 가중치를 계산해 업데이트한다.

```
cos_dist_i = 1 - cosine_sim(v_i, e)      # 코사인 거리
weight_i   = exp(-cos_dist_i / τ)        # 온도 τ로 softness 조절
weight_i   /= Σ weight_j                 # 정규화 (합 = 1)

v_i += sign · α · weight_i · normalize(e) # 가중 업데이트
```

이벤트	sign	α	의미
검색 발생	+1	alpha_search	interest를 검색 방향으로 당김
광고 클릭	+1	alpha_click	interest를 클릭 광고 방향으로 강하게 당김
광고 비클릭	-1	alpha_neg	interest를 비클릭 광고 반대 방향으로 밀

예측

Task A (Ad Recommendation)

$$\text{score}_j = (1 - \gamma) \cdot \text{sim}(q, a_j) + \gamma \cdot \max_i \text{sim}(v_i, a_j)$$

후보 광고 전체에 대해 score를 계산 후 argmax의 AdID를 반환한다.

Task B (Click Prediction)

$$\text{score} = \max_i \text{cosine_sim}(v_i, a)$$

score > (1 - threshold) 이면 클릭(1), 아니면 비클릭(0)으로 예측한다.

2. 실험 설정

2-1. 데이터셋

항목	수치
총 유저	16,975명
검색 이벤트	276,807건
광고 수	17,518개
훈련 행	320,000건
전체 CTR	1.11% (클릭 3,560 / 전체 320,000)
클릭 발생 유저	2,385명 (전체의 14%)
클릭 유저 1인당 평균 클릭 수	1.49회
임베딩 차원	384

2-2. Hyperparameter

파라미터	초기값	Step 5 수정값	설명
k	5	5	interest vector 개수
alpha_search	0.1	0.01	검색 업데이트 강도
alpha_click	0.5	0.5	클릭 업데이트 강도
alpha_neg	0.0	0.0	비클릭 페널티 (비활성)
temperature	1.0	1.0	soft assignment 온도
gamma	0.5	0.5 (adaptive)	user interest 혼합 비율
threshold	0.5	0.5	클릭 판정 임계값 (Task B)

2-3. 평가 지표

Task	지표	정의
A	Accuracy	정답 AdID를 1위로 예측한 비율
A	AUC	정답 광고가 임의 오답보다 높은 점수를 받을 확률 (ranking AUC)

Task	지표	정의
A	MRR	Mean Reciprocal Rank — 1/(정답 순위)의 평균
B	Accuracy	전체 정확도
B	Precision	클릭으로 예측한 것 중 실제 클릭 비율 — IsClick=1 기준
B	Recall	실제 클릭 중 올바르게 탐지한 비율 — IsClick=1 기준
B	F1	클릭 클래스 F1 — IsClick=1 기준
B	AUC	ROC AUC (Wilcoxon-Mann-Whitney 통계량)

2-4. 비교 베이스라인

모델	설명
MultInterest (ours)	본 모델
Query-only (gamma=0)	user interest 없이 query-ad 유사도만 사용
Random	무작위 예측
Always-0	항상 비클릭으로 예측
Always-1	항상 클릭으로 예측

3. 실험 결과

3-1. Task A — Ad Recommendation (214 queries, 17,518 candidates)

Step 4 (초기 결과, alpha_search=0.1)

모델	Accuracy	AUC	MRR
MultInterest (ours)	0.0748	0.8417	0.1337
Query-only (gamma=0)	0.0607	0.8454	0.1197
Random	0.0000	0.5047	0.0007

Step 5 (개선 후, alpha_search=0.01 + adaptive gamma)

모델	Accuracy	AUC	MRR
MultInterest (ours)	0.0748	0.8500	0.1428
Query-only (gamma=0)	0.0607	0.8454	0.1197
Random	0.0000	0.5047	0.0007

Confusion (Task A — Step 5)

	Correct	Wrong	Total
Queries	16	198	214

3-2. Task B — Click Prediction (20,000 queries, CTR 1.15%)

Step 4 (초기 결과)

모델	Accuracy	Precision	Recall	F1	AUC
MultInterest (ours)	0.8762	0.0049	0.0480	0.0088	0.4164
Always-0 (no click)	0.9886	0.0000	0.0000	0.0000	0.5000
Always-1 (all click)	0.0115	0.0115	1.0000	0.0226	0.5000

Step 5 (개선 후)

모델	Accuracy	Precision	Recall	F1	AUC
MultInterest (ours)	0.5686	0.0131	0.4934	0.0255	0.5334
Always-0 (no click)	0.9886	0.0000	0.0000	0.0000	0.5000
Always-1 (all click)	0.0115	0.0115	1.0000	0.0226	0.5000

Precision / Recall / F1: IsClick=1 기준

Per-class (MultInterest, Step 5)

Class	TP	FP	FN	Precision	Recall	F1	Support
0 (no-click)	11,260	116	8,511	0.9898	0.5695	0.7230	19,771
1 (click)	113	8,511	116	0.0131	0.4934	0.0255	229

Confusion Matrix (Task B — Step 5)

	Pred 0	Pred 1
True 0 (19,771)	11,260 (TN)	8,511 (FP)
True 1 (229)	116 (FN)	113 (TP)

Threshold Sweep (MultInterest, Step 5)

Threshold	Accuracy	Precision	Recall	F1
0.1	0.9710	0.0111	0.0175	0.0136
0.2	0.9281	0.0152	0.0830	0.0257
0.3	0.8325	0.0107	0.1485	0.0199

Threshold	Accuracy	Precision	Recall	F1
0.4	0.7046	0.0129	0.3275	0.0248
0.5	0.5686	0.0131	0.4934	0.0255
0.6	0.4155	0.0124	0.6376	0.0244
0.7	0.2494	0.0125	0.8253	0.0246
0.8	0.1134	0.0119	0.9345	0.0236
0.9	0.0309	0.0116	0.9956	0.0230

F1 최대값은 threshold=0.2 (F1=0.0257). Precision-Recall tradeoff 상 threshold를 낮추면 Recall이 급감하고, 높이면 Precision이 급감한다. 근본 원인은 클래스 불균형(CTR 1.15%)에 있으므로 F1 수치 자체는 낮다.

4. 분석

4-1. Task A — Step 5 결과 분석

개선 효과

지표	Step 4	Step 5	변화
Accuracy	0.0748	0.0748	-
AUC	0.8417	0.8500	+0.0083
MRR	0.1337	0.1428	+0.0091

- alpha_search를 0.1 → 0.01로 낮추자 interest vector가 클릭 신호에 더 민감하게 수렴했다.
- **Step 5에서 MultiInterest AUC(0.8500) > Query-only AUC(0.8454)**: 이제 user interest가 랭킹 순서도 개선한다.
- Accuracy는 동일(16/214): 단순 top-1 정확도는 클릭 집계 품질보다 데이터 분산이 지배적.
- Adaptive gamma: 클릭 이력 없는 유저(86%)를 query-only로 폴백시켜 noise interest 혼입을 방지.

4-2. Task B — Step 5 결과 분석

핵심 개선: AUC 0.4164 → 0.5334 (역상관 해소)

지표	Step 4	Step 5	변화
Accuracy	0.8762	0.5686	-
Precision	0.0049	0.0131	+168%
Recall	0.0480	0.4934	+928%
F1	0.0088	0.0255	+190%
AUC	0.4164	0.5334	+0.1170

Step 4의 AUC < 0.5 문제가 해소됐다. 두 수정이 각각 다른 효과를 냈다.

[수정 2] score_click에 query-ad 유사도 추가 → AUC 반전의 핵심

Step 4의 $\text{score_click} = \max_i \text{cosine_sim}(v_i, \text{ad})$ 는 interest vector가 검색 방향으로 쏠려있어 클릭과 역방향 상관관계를 가졌다. Step 5에서 $(1-\text{gamma}) * \text{sim}(\text{query}, \text{ad}) + \text{gamma} * \max_i \text{sim}(v_i, \text{ad})$ 로 바꾸자 query-ad 유사도가 강한 양의 클릭 신호를 제공하며 AUC가 0.5를 넘겼다.

[수정 3] alpha_search 0.1 → 0.01 → Interest 품질 개선

검색 이벤트가 클릭보다 ~50배 많아 누적 업데이트가 클릭 신호를 압도했다. alpha_search를 1/10로 줄이자 interest vector가 클릭 방향을 더 잘 보존한다.

잔존 문제: Precision 극히 낮음

- CTR 1.15% 극단적 클래스 불균형 → threshold=0.5에서 8,511건(42.6%)을 클릭으로 예측, 실제 클릭은 113건만 맞힘
- Threshold=0.2에서 F1이 0.0257로 미세하게 최대 (Precision 1.52%, Recall 8.3%)
- 근본 원인: score 분포가 클릭/비클릭 간 충분히 분리되지 않음 → 미래 개선 필요

5. 개선 방향

5-1. 즉시 적용 가능한 수정 (Step 5 우선순위)

[수정 1] Task A: gamma 최적화 (기대 효과: AUC +)

현재 gamma=0.5로 user interest와 query-ad 유사도를 동등하게 혼합한다.

Query-only AUC가 더 높으므로, gamma를 줄이거나 **interest가 충분히 축적된 유저에게만** 높은 gamma를 적용하는 adaptive gamma를 도입한다.

```
# 예시: 클릭 이력이 있는 유저에게만 gamma 적용
effective_gamma = gamma if user_has_click_history else 0.0
```

[수정 2] Task B: score에 query-ad 유사도 추가

```
score_click = (1 - gamma) * cosine_sim(query, ad)
              + gamma      * max_i cosine_sim(v_i, ad)
```

Task A와 동일한 scoring 함수를 Task B에도 적용해 검색 맥락을 반영한다.

[수정 3] 검색 업데이트 비중 재조정

현재 alpha_search=0.1은 이벤트 수 차이를 보정하지 않는다.

검색 횟수가 클릭 횟수보다 평균 ~50배 많으므로, 누적 영향이 클릭의 5배가 된다.

```
# 옵션 A: alpha_search를 대폭 줄이기 (예: 0.01)
# 옵션 B: 검색 업데이트를 완전히 끄고 클릭 신호만 사용 (alpha_search=0)
```

[수정 4] Task B: threshold sweep으로 최적값 탐색

score + threshold를 바꿔도 AUC가 0.5 미만이면 score 자체를 바꿔야 하지만,
[수정 2] 적용 후 AUC가 0.5를 넘는다면 threshold 튜닝으로 F1을 높일 수 있다.

```
for threshold in [0.3, 0.4, 0.5, 0.6, 0.7, 0.8]:
    metrics = evaluate_task_b(scores, answers_df, threshold)
    # F1이 최대인 threshold 선택
```

5-2. 중기 개선 아이디어

아이디어	기대 효과	복잡도
Cold-start 처리: 클릭 이력 없는 유저는 query-only score 사용	Task B AUC 개선	낮음
HistCTR 피처 활용: 광고의 과거 클릭률을 score에 가산	Task B Precision 개선	낮음
k 튜닝: 클릭 희소성 감안해 k=1~2로 줄이기	Interest 수렴 속도 향상	낮음
Temporal decay: 오래된 업데이트에 감쇠 계수 적용	Interest drift 대응	중간
Category 필터: 동일 CategoryID 광고를 우선 후보로	Task A Accuracy 개선	중간

6. 결론

관점	평가
Task A Retrieval	유효: AUC 0.84, Accuracy 10.3% — text embedding 기반 retrieval이 강한 신호를 제공
Task A User Interest	부분 유효: Accuracy는 향상되나 AUC는 소폭 하락 — gamma 조정 필요
Task B Click Prediction	미흡: AUC 0.41 (< 0.5) — interest score가 역방향. 검색 의도 반영 및 업데이트 비중 재조정 필요
전체 방향성	text embedding 기반 접근은 Task A에서 명확한 가능성을 보여주며, Task B는 score 설계를 보완하면 개선 여지가 크다

다음 Step (Step 5) 우선순위: [수정 2] Task B score에 query-ad 유사도 추가 → [수정 3] alpha_search 재조정 → [수정 1] adaptive gamma → threshold sweep